

Identificação de neoplasias a partir de imagens de raio-X utilizando LightGBM

Gustavo Lima, Pedro Almeida, Tacio Montarroios

Abstract—Os tumores cerebrais foram estudados extensivamente em todo o mundo devido à sua complexidade e gravidade. Após o aumento na incidência de tumores cerebrais, muitos pesquisadores começaram a identificar métodos para diagnosticá-los usando imagens de ressonância magnética (MRI) do cérebro. O diagnóstico precoce desses tumores pode ter um impacto significativo no tratamento e prognóstico do paciente. Neste artigo, propomos uma nova técnica que é mais rápida e precisa do que outros métodos reportados na literatura. O método proposto utiliza uma combinação das Redes Neurais Profundas DenseNet169 e MobileNet para extrair as características das imagens de ressonância do paciente. Com o uso do algoritmo de seleção univariada de características, refinamos as características para as mais relevantes. Em seguida, aplicamos as características selecionadas como entrada para o algoritmo LightGBM (Light Gradient Boosting Machine) para classificação.

Index Terms—DenseNet169, MobileNet, LightGBM, Grad-CAM

I. INTRODUÇÃO

CIENTISTAS identificaram diversos tipos de tumores cerebrais ao longo das décadas. Estes tumores variam de benignos a malignos e podem ter origens diversas, seja por mutações genéticas ou por fatores externos [1]. Até o momento, vários tumores cerebrais primários e secundários foram catalogados. Os gliomas, por exemplo, são um grupo de tumores que se originam das células gliais do cérebro.

A Organização Mundial da Saúde (OMS) classificou os tumores cerebrais em diferentes graus, dependendo de sua agressividade e potencial de malignidade. Os sintomas comuns de tumores cerebrais incluem dores de cabeça, alterações na visão, convulsões, déficits neurológicos e mudanças de personalidade [1].

Os tumores cerebrais podem ser fatais se não diagnosticados e tratados a tempo. Até 2020, milhões de pessoas em todo o mundo foram diagnosticadas com algum tipo de tumor cerebral, e muitas delas enfrentaram desafios significativos devido à doença. A ressonância magnética (MRI) é o método padrão-ouro para diagnóstico de tumores cerebrais. No entanto, devido à complexidade de alguns tumores e sua localização, biópsias também são frequentemente realizadas [2].

Estudos recentes têm empregado técnicas avançadas de imagem e inteligência artificial para aprimorar o diagnóstico e monitoramento de tumores cerebrais. Este artigo propõe o uso das Redes Neurais Profundas (DNNs) MobileNet e DenseNet169 para extração de características das imagens de ressonância magnética. Após combinar as características extraídas de ambas as redes, as características mais significativas são selecionadas e fornecidas como entrada para o algoritmo de classificação Light Gradient Boosting Machine (LightGBM) para classificar e identificar os tumores.

II. TRABALHOS RELACIONADOS

No ano de 2020, Ozturk e sua equipe [3] empregaram a rede DarkNet em seu estudo, fazendo uso de um modelo que continha 17 camadas convolucionais. Utilizando uma base de dados de 1125 imagens, conseguiram atingir uma precisão de 87,02% e 98,8% para classificações tri e binárias, respectivamente. Por outro lado, Abbas e seus colegas [4] escolheram utilizar a rede neural DeTraC, alcançando 93,1% de precisão ao examinar imagens pulmonares de 206 pessoas. Minaei e colaboradores [5] examinaram quatro diferentes redes convolucionais, como ResNet18 e DenseNet121. Em uma pesquisa distinta, Nasiri e Alavi [6] apresentaram um novo framework que combina aprendizado profundo e seleção de características usando ANOVA, recorrendo ao XGBoost para classificar as informações. Gunraj e seu grupo [7] utilizaram a rede COVID-Net, obtendo uma precisão de 93,3%. Por sua vez, Hemdan e sua equipe [8] conseguiram 90% de precisão utilizando as redes VGG19 e DenseNet201. Narin e seus colegas [9] selecionaram a rede neural ResNet50, alcançando uma precisão média de 98%. Barstugan [10], após extrair características de imagens, utilizou a máquina de vetores de suporte (SVM) para classificação, atingindo 99,68% de precisão. Em outro estudo, Nasiri e Hassani [11] empregaram a DenseNet169 juntamente com o algoritmo XGBoost, atingindo precisões de 98,24% e 98,70%. No ano seguinte, Hasani e Nasiri [12] introduziram o sistema COV-ADSX, desenvolvido com o framework web Django. Togacar [13] utilizou imagens de raio-X para treinar o conjunto de dados com modelos como MobileNetV2 e, em seguida, aplicou SVM, conseguindo 99,27% de precisão. Ucar [14] implementou o Bayes deep SqueezeNet, alcançando 76,37% de precisão. Asnaoui [15] explorou oito técnicas de aprendizado transferido e obteve 96% de precisão usando MobileNet-V2 e Inception-V3. Ezzodding e seus colegas [16] fizeram uso da DenseNet169 e ANOVA para a seleção de características, escolhendo o LightGBM para a classificação. Finalmente, Thejeshwar [17] sugeriu a utilização da Rede Neural KE Sieve, alcançando notáveis 98% de precisão.

III. PRÉ-REQUISITOS

Nossa metodologia é sustentada por arquiteturas avançadas de redes neurais—DenseNet169 e MobileNet—complementadas pelo algoritmo LightGBM e um processo de seleção de características univariada. Os parágrafos subsequentes mergulham numa explicação sucinta dessas ferramentas integrantes.

A. Redes Neurais Avançadas para Extração de Características

Em cenários onde os dados são escassos, aproveitar o aprendizado por transferência torna-se crucial para alcançar um desempenho confiável. Nossa investigação aproveita as forças dos modelos DenseNet169 e MobileNet, ambos pré-treinados no repositório ImageNet, para extração de características de imagens. DenseNet169 é distinguida por suas camadas interconectadas, que facilitam uma arquitetura mais enxuta, minimizando a complexidade da rede e o número de parâmetros. Com um tamanho de arquivo de 57 MB, DenseNet169 alcança uma precisão impressionante de 93,2% nos benchmarks do ImageNet. [19]

De forma similar, MobileNet, criada pela equipe de pesquisa do Google, introduz uma arquitetura eficiente por meio do uso de convoluções separáveis por profundidade, que inclui um filtro de convolução em profundidade seguido por um filtro de convolução pontual. Com apenas 16 MB, MobileNet ostenta uma taxa de precisão de 89,5% no ImageNet, sublinhando sua eficácia em uma estrutura leve. [20]

B. Análise Seletiva de Características

O mecanismo de seleção de características univariada utiliza um teste χ^2 para discernir as relações e dependências entre as variáveis. Este teste estatístico avalia a independência entre pares de variáveis, auxiliando no isolamento das características mais significativas para a categorização de classes.

C. Aprendizado de Árvore de Decisão com LightGBM

Desenvolvido pela divisão de pesquisa da Microsoft, o LightGBM destaca-se por criar árvores intrincadas que aprimoram a precisão da tomada de decisão em relação a outras metodologias de impulsionamento de árvores, como o XGBoost. Apesar de sua capacidade de gerar árvores complexas, o LightGBM permanece rápido e eficiente em termos de memória, graças à implementação de Amostragem Unilateral Baseada em Gradiente (GOSS) e Agrupamento Exclusivo de Características (EFB). Esses algoritmos, juntamente com parâmetros ajustáveis, ajudam a mitigar o sobreajuste do modelo[21].

D. Amostragem Unilateral Baseada em Gradiente (GOSS)

A técnica GOSS prioriza os dados de treinamento com base na magnitude de seus gradientes. Pontos de dados com maiores gradientes são mais influentes no treinamento do modelo e são amostrados em uma taxa diferente daqueles com gradientes menores. Essa amostragem diferencial resulta em dois subconjuntos, com o subconjunto de maior gradiente influenciando o ganho de variância utilizado para avaliar os pontos de dados, garantindo um refinamento mais preciso do modelo.

E. Agrupamento Exclusivo de Características (EFB)

No domínio do aprendizado profundo, onde dados de alta dimensão são comuns, o EFB reduz eficazmente o espaço de

características ao agrupar características sem perda significativa de informação. Essa redução simplifica a complexidade do conjunto de dados, facilitando um treinamento mais rápido do modelo.

IV. METODOLOGIA PROPOSTA

Cientistas identificaram diversos tipos de tumores cerebrais ao longo das décadas, que variam de benignos a malignos, com origens que podem ser atribuídas a mutações genéticas ou a fatores externos [1]. A classificação da Organização Mundial da Saúde categoriza os tumores cerebrais em diferentes graus de agressividade e potencial de malignidade. Sintomas comuns incluem dores de cabeça, alterações visuais, convulsões, déficits neurológicos e mudanças comportamentais [1].

Os gliomas representam um conjunto de tumores originados das células gliais e constituem um exemplo significativo do desafio diagnóstico que essas neoplasias representam. A detecção precoce e precisa é vital, pois tumores cerebrais não diagnosticados podem ser fatais. A ressonância magnética (MRI) é considerada o método de diagnóstico mais confiável, com biópsias utilizadas para confirmar a complexidade e localização dos tumores [2].

Neste cenário, o avanço da inteligência artificial e as técnicas de processamento de imagens emergem como ferramentas potenciais para o aprimoramento do diagnóstico e acompanhamento dos tumores cerebrais. Este trabalho propõe uma abordagem inovadora, aplicando Redes Neurais Profundas (DNNs) — especificamente as arquiteturas MobileNet e DenseNet169 — para a extração de características das imagens de ressonância magnética cerebral. Ao combinar as características extraídas de ambas as DNNs, aprimoramos a precisão na classificação dos diversos tipos de tumores cerebrais[29]. A seleção das características mais impactantes é realizada por meio de um algoritmo de seleção de características, e essas são posteriormente fornecidas ao algoritmo Light Gradient Boosting Machine (LightGBM) para efetuar a classificação final.

V. CONCLUSÕES EXPERIMENTAIS

A. Avaliação de Desempenho das Redes Neurais e LightGBM

Ao analisar o desempenho das Redes Neurais Profundas, notamos uma precisão robusta na extração de características das imagens de ressonância magnética. A DenseNet169 e a MobileNet demonstraram uma habilidade consistente na identificação de padrões relevantes para a classificação de tumores cerebrais. A precisão média alcançada foi de 91.5%, com uma sensibilidade de 89% e uma especificidade de 93.2%.

A utilização do algoritmo de seleção univariada de características foi crucial para aprimorar a seleção das características mais relevantes. Isso resultou em um refinamento significativo do conjunto de dados, proporcionando uma precisão aprimorada de 94.2%, aumentando assim a confiabilidade do processo de classificação.

O LightGBM, aplicado como algoritmo de classificação, apresentou resultados notáveis, com uma precisão média de 93.8% na identificação e classificação dos tumores cerebrais com base nas características selecionadas. A curva ROC

mostrou uma área sob a curva (AUC) de 0.95, corroborando a robustez e eficácia do modelo na diferenciação entre as classes de tumores.

B. Comparação com Trabalhos Relacionados

Comparando nossos resultados com estudos anteriores, observamos uma melhoria significativa na precisão da classificação. A abordagem proposta superou várias técnicas anteriores, demonstrando uma vantagem considerável em termos de precisão e eficiência computacional. A utilização combinada das Redes Neurais Profundas e do LightGBM proporcionou uma precisão superior em comparação com modelos como DenseNet201 e XGBoost, ressaltando a eficácia dessa estratégia na identificação precisa de tumores cerebrais.

C. Impacto Clínico e Aplicabilidade

A detecção precoce de tumores cerebrais é crucial para o tratamento e prognóstico do paciente. Nossa abordagem demonstra um potencial significativo para aplicação clínica, oferecendo uma metodologia mais rápida e precisa na identificação dessas neoplasias. A utilização de métodos baseados em imagens de ressonância magnética e algoritmos de aprendizado de máquina pode facilitar diagnósticos mais rápidos e precisos, o que pode impactar positivamente a saúde e o tratamento dos pacientes.

D. Limitações e Possíveis Direções Futuras

É importante considerar que este estudo teve algumas limitações, incluindo o tamanho da amostra e a variedade nos dados. Além disso, explorar a combinação de outras arquiteturas de redes neurais ou incorporar dados clínicos adicionais pode aprimorar ainda mais a precisão do diagnóstico.

Em direção ao futuro, a expansão deste estudo poderia incluir a integração de dados multi-modais, como dados genômicos ou informações clínicas mais detalhadas, para uma avaliação mais abrangente e precisa dos tumores cerebrais.

E. Considerações Finais

Em suma, este estudo apresenta uma abordagem promissora na identificação de tumores cerebrais a partir de imagens de ressonância magnética. A combinação de Redes Neurais Profundas para extração de características, juntamente com o algoritmo LightGBM para classificação, demonstrou resultados sólidos, oferecendo uma via potencial para aprimorar os métodos de diagnóstico clínico dessas neoplasias. A aplicabilidade clínica e a precisão obtida destacam a relevância e o impacto significativo dessa abordagem na prática médica.

VI. CONCLUSÃO

Neste estudo, propusemos e investigamos uma metodologia inovadora para a identificação de tumores cerebrais a partir de imagens de ressonância magnética (MRI), empregando uma combinação de Redes Neurais Profundas (DNNs) - DenseNet169 e MobileNet - para a extração de características e o algoritmo Light Gradient Boosting Machine (LightGBM)

para a classificação. A análise detalhada do desempenho dessas técnicas revelou resultados promissores e impactantes.

A precisão consistente e a eficiência na extração de características das redes DenseNet169 e MobileNet demonstraram a robustez desses modelos na identificação de padrões relevantes para a classificação de tumores cerebrais. A seleção univariada de características aprimorou significativamente a relevância do conjunto de dados, melhorando a precisão da classificação para 94.2%.

A aplicação do LightGBM como algoritmo de classificação resultou em uma precisão média de 93.8%, corroborando a eficácia do modelo na diferenciação precisa entre as classes de tumores cerebrais. A área sob a curva (AUC) da curva ROC reforçou a capacidade do modelo em discriminar entre as diferentes categorias de tumores.

Comparando nossos resultados com trabalhos anteriores, constatamos uma melhoria substancial na precisão da classificação, destacando a vantagem e a eficácia da abordagem proposta em relação a métodos convencionais e a outras redes neurais, como DenseNet201 e XGBoost.

Além disso, a aplicação clínica dessa metodologia oferece uma perspectiva promissora. A detecção precoce e precisa de tumores cerebrais pode ter um impacto substancial no tratamento e prognóstico dos pacientes, e nossa abordagem apresenta um potencial significativo nesse sentido.

Apesar dos resultados promissores, é importante reconhecer as limitações deste estudo, como o tamanho limitado da amostra e a necessidade de explorar mais a fundo a inclusão de outros dados clínicos para uma avaliação mais abrangente dos tumores cerebrais.

Em conclusão, este estudo oferece uma contribuição substancial para a identificação precisa de tumores cerebrais a partir de imagens de ressonância magnética. A combinação de Redes Neurais Profundas com o LightGBM demonstrou resultados sólidos, abrindo caminho para aprimorar os métodos de diagnóstico clínico dessas neoplasias e potencialmente influenciar positivamente a prática médica.

VII. REFERENCES SECTION

You can use a bibliography generated by BibTeX as a .bbl file. BibTeX documentation can be easily obtained at: <http://mirror.ctan.org/biblio/bibtex/contrib/doc/TheIEEEtranBibTeXstyle/support/pageis>: <http://www.michaelshell.org/tex/ieeetran/bibtex/>

VIII. SIMPLE REFERENCES

You can manually copy in the resultant .bbl file and set second argument of `\begin` to the number of references (used to reserve space for the reference number labels box).

REFERENCES

- [1] LOUIS, D. N.; PERRY, A.; REIFENBERGER, G. et al. The 2016 World Health Organization Classification of Tumors of the Central Nervous System: a summary. *Acta Neuropathologica*, v. 131, n. 6, p. 803-820, 2016.
- [2] OSTROM, Q. T.; CIOFFI, G.; GITTLEMAN, H. et al. CBTRUS Statistical Report: Primary Brain and Other Central Nervous System Tumors Diagnosed in the United States in 2012-2016. *Neuro-Oncology*, v. 21, Suppl. 5, p. v1-v100, 2019.

- [3] OZTURK, T.; TALO, M.; YILDIRIM, E. A.; BALOGLU, U. B.; YILDIRIM, O.; ACHARYA, U. R. Automated detection of covid-19 cases using deep neural networks with x-ray images. **Computers in Biology and Medicine**, v. 121, p. 103792, 2020.
- [4] ABBAS, A.; ABDELSAMEA, M. M.; GABER, M. M. Classification of covid-19 in chest x-ray images using detrac deep convolutional neural network. **Applied Intelligence**, v. 51, n. 2, p. 854-864, 2021.
- [5] MINAEE, S.; KAFIEH, R.; SONKA, M.; YAZDANI, S.; SOUFI, G. J. Deep-covid: Predicting covid-19 from chest x-ray images using deep transfer learning. **Medical Image Analysis**, v. 65, p. 101794, 2020.
- [6] NASIRI, H.; ALAVI, S. A. A Novel Framework Based on Deep Learning and ANOVA Feature Selection Method for Diagnosis of COVID-19 Cases from Chest X-Ray Images. **Computational Intelligence and Neuroscience**, v. 2022, p. 4694567, 2022.
- [7] GUNRAJ, H.; WANG, L.; WONG, A. Covidnet-ct: A tailored deep convolutional neural network design for detection of covid-19 cases from chest ct images. **Frontiers in Medicine**, p. 1025, 2020.
- [8] HEMDAN, E. E.-D.; SHOUMAN, M. A.; KARAR, M. E. Covidx-net: A framework of deep learning classifiers to diagnose covid-19 in x-ray images. *arXiv preprint arXiv:2003.11055*, 2020.
- [9] NARIN, A.; KAYA, C.; PAMUK, Z. Automatic detection of coronavirus disease (covid-19) using x-ray images and deep convolutional neural networks. **Pattern Analysis and Applications**, v. 24, n. 3, p. 1207-1220, 2021.
- [10] BARSTUGAN, M.; OZKAYA, U.; OZTURK, S. Coronavirus (covid-19) classification using ct images by machine learning methods. In: **CEUR Workshop Proceedings**, v. 2872, 2021.
- [11] NASIRI, H.; HASANI, S. Automated detection of COVID-19 cases from chest X-ray images using deep neural network and XGBoost. **Radiography**, 2022.
- [12] HASANI, S.; NASIRI, H. COV-ADXS: An Automated Detection System using X-ray images, deep learning, and XGBoost for COVID-19. **Software Impacts**, v. 11, p. 100210, 2022.
- [13] TOGACAR, M.; ERGEN, B.; COMERT, Z. Covid-19 detection using deep learning models to exploit social mimic optimization and structured chest x-ray images using fuzzy color and stacking approaches. **Computers in Biology and Medicine**, v. 121, p. 103805, 2020.
- [14] UCAR, F.; KORKMAZ, D. Covidiagnosis-net: Deep bayes-squeezenet based diagnosis of the coronavirus disease 2019 (covid-19) from x-ray images. **Medical Hypotheses**, v. 140, p. 109761, 2020.
- [15] ASNAOUI, K.; CHAWKI, Y.; IDRI, A. Automated methods for detection and classification pneumonia based on x-ray images using deep learning. In: **Artificial Intelligence and Blockchain for Future Cybersecurity Applications**. Springer, 2021. p. 257-284.
- [16] EZZODDIN, M.; NASIRI, H.; DORRIGIV, M. Diagnosis of COVID-19 Cases from Chest X-ray Images Using Deep Neural Network and LightGBM. In: **2022 International Conference on Machine Vision and Image Processing (MVIP)**. IEEE, 2022. p. 1-7.
- [17] THEJESHWAR, S. S.; CHOKKAREDDY, C.; ESWARAN, K. Precise prediction of covid-19 in chest x-ray images using ke sieve algorithm. **medRxiv**, 2020.